

机器学习入门指南

前言

这是一个颇具挑战性的任务，但对于完全没有接触过的你而言，不用害怕，本文将介绍一些互联网上的资源，方便你无痛入门机器学习，逐渐构建起自己对机器学习领域的见解。除此之外，也希望你能在探索机器学习的路上总结出一套自己的学习方法论：当你在面对下一个自己完全没接触过的领域时，你该如何勇敢、快速、高效的去面对这次新的挑战？

本文推荐的入门时长为两月左右，可根据自己的进度与规划安排学习时间。

理论的价值在于指导实践，学习的目的全在于运用。机器学习的发展也是在理论与实验的相互反哺中进步的。基本功的学习也分为了两大部分：

- 机器学习基本理论
 - 机器学习基本概念，基本运作思路
 - 前向传播？反向传播？梯度下降？训练集测试集？...
 - 经典而常用的网络
 - CNN、RNN、Transformer...
- 机器学习的实验基础
 - 配置环境
 - Python
 - Pytorch
 - git
 - Linux 基本命令

打好基本功后，你会开始在机器学习的某一领域继续深耕，你需要掌握：

- 如何有效的阅读论文
- 扎实的数学基本功：概率论与数理统计、微积分、线性代数

资源推荐

下面推荐一些课程与书籍：

基本理论学习：

1. 李沐机器学习：<https://courses.d2l.ai/zh-v2/>（可自行选择最新版本）

- 资料的优点在于，比较有规律，注重代码实践（有完整配套的视频、PPT、课本）一个课程就能达到不错的理论和实验基础
- 2. 李宏毅老师系统课程，2022 版 b 站上有授权正版课程
 - 幽默风趣，讲的很有意思
 - 2022 版侧重机器学习的基本知识
 - 课后作业有一定难度，需要思考，但是做了收获很大，提供作业思路参考的博客主页（可以全局搜索关键词”HW”找到相应的作业博客）<https://www.zhihu.com/people/lao-ma-wo-er-zi>

在本指南的规划中，主要采用的是李沐的机器学习，可以结合自己的情况决定是否观看李宏毅老师的课程。

1. 《机器学习》 周志华 著 清华大学出版社
 - 又名西瓜书，非常详尽的介绍了机器学习的基本知识，常见算法以及进阶知识，十分经典，推荐人手一本
 - 先看完 1~3 章以及第五章，其他章节可以稍后再看。

机器学习的实验基础

b 站上的教程很多，大家可以根据自己喜好搜索，下面列出几个任务点。找几个课程学习实践基础效果不好，这类知识的学习需要秉持“To learn by doing”的理念，建议大家给自己布置一个项目（后面本文会有一个推荐的项目），通过实际上手写代码来学习，亲手配置环境，动手实验一些 pytorch 函数的效果，在视屏的引导下写下自己第一个 dataloader、第一个网络，自己调整参数，观察实验效果。当然，这部分的学习需要机器学习理论基础的支撑。

- 搭建 Linux 编程环境
 - 虚拟机（不推荐）
 - WSL（推荐）
 - 安装 Linux 系统（推荐）
 - SSH 远程连接 Linux 服务器（推荐）
- 配置 Anaconda
- 配置 Docker（可选）
- 学习 python
 - 有 c 语言的基础下，一周内铁能学会
- 学习 pytorch
 - https://www.bilibili.com/video/BV1QT411B7Aj?spm_id_from=33.1387.favlist.content.click

进阶

- 继续阅读西瓜书的剩余章节
- 深度学习论文精读（李沐）
 - <https://github.com/mlj/paper-reading>
 - b 站：李沐带你读论文

- 于静老师近期在 B 站开设了《科研与英文学术论文写作》视频课程

https://www.bilibili.com/video/BV1aa41lH757?spm_id_from=333.337.search-card.all.click

实践演练

这是两个检验你学习效果的任务，尝试着完成吧！不要留着把课和书刷完了再做这两个任务，你完全可以边学边做，这有助于你更深入的理解你学习到的理论知识。

1. 自行尝试一下 MINIST 手写数字识别，可谓 ai 版本的 “hello world!”
2. 自行复现一个 Transformer 模型。这个任务会有些难度：
 - 了解 Transformer 的基本原理——视频、以及论文《Attention is all you need》
 - 可以参考一下网上的复现教程

第一周：深度学习基础

任务

1. 完成李沐机器学习：<https://courses.d2l.ai/zh-v2/>深度学习基础中的
 - 深度学习介绍、安装、数据操作、数据预处理
 - 线性代数、按特定轴求和、矩阵计算、自动求导
 - 线性回归、基础优化方法、线性回归的从零开始实现、线性回归的简单实现
 - Softmax 回归、损失函数、图像分类数据集、Softmax 回归的从零开始实现、Softmax 回归的简洁实现
2. git 代码仓库的学习
 - [Git 使用教程,最详细,最傻瓜,最浅显,真正手把手教 - 知乎 \(zhihu.com\)](#)
 - [收藏了! Git 核心操作图解 \(qq.com\)](#)
 - [GitHub 仓库快速导入 Gitee 及同步更新 - Gitee.com](#)
 - [Gitee 帮助中心 - Gitee.com](#)

输出

1. 在 [Gitee](#) 上，建立自己的笔记仓库，利用 git 工具进行自己笔记的版本管理，学会分支、合并等基本操作
2. 视频课程学习笔记并将自己的笔记上传到在上建立的自己的 gitee 笔记仓库中，作业部分不用完成（可以根据视频讲解和博主提供的 git/gitee 仓库中的内容学习）

第二周：深度学习基础

任务

1. 完成李沐机器学习：<https://courses.d2l.ai/zh-v2/>深度学习基础中的
 - 感知机、多层感知机、多层感知机的从零开始实现、多层感知机的简洁实现
 - 模型选择、欠拟合和过拟合
 - 权重衰减、Dropout
 - 数值稳定性、模型初始化和激活函数
 - 实战 Kaggle 比赛：预测房价【动手写】
2. Linux 环境配置以及基本命令
 - 在 windows 上运行 WSL2
 - [适用于 Linux 的 Windows 子系统文档 | Microsoft Docs](#)
 - [Windows10/11 三步安装 wsl2 Ubuntu20.04 \(任意盘\) - 知乎 \(zhihu.com\)](#)
 - 在 windows 子系统 WSL2 中建立 Ubuntu 环境
 - 了解 Linux 基本操作
 - [第一章：引言 The Linux Command Line 中文版 · 看云 \(kancloud.cn\)](#)

输出

1. 视频课程学习笔记并上传到自己的 gitee 笔记仓库中
2. 完成 linux 的配置以及基本操作的学习

第三周：卷积神经网络

任务

1. 完成李沐机器学习：<https://courses.d2l.ai/zh-v2/>卷积神经网络中的
 - 模型构造、参数管理、自定义层、读写文件、GPU
 - 从全连接层到卷积、图像卷积

- 填充和步幅、多输入多输出通道
 - 池化层、卷积神经网络（LeNet）
- 2. 在 WSL2 下安装 anaconda 并配置 PyTorch 环境（PyTorch 有 GPU 版和 CPU 版，个人笔记本上使用 CPU 版就行，后续进入实验室后会分配有 GPU 的服务器）
 - 安装方法自行搜索，例如 [linux 安装 anaconda 及配置 pytorch 环境](#)
- 3. 在 WSL2 中安装 jupyter notebook，在 windows 中打开可视化界面，并熟悉 jupyter 使用方法
 - 安装方法自行搜索，例如[搭建 Python 轻量级编写环境（WSL2+Jupyter 自动开启本地浏览器） - 知乎 \(zhihu.com\)](#)
 - 使用方法：
 - [Jupyter Notebook 介绍、安装及使用教程 - 知乎 \(zhihu.com\)](#)
 - [最详尽使用指南：超快上手 Jupyter Notebook - 知乎 \(zhihu.com\)](#)

输出

1. 视频课程学习笔记
2. 完成环境配置以及对 PyTorch 的初步了解
3. 初步了解 PaddlePaddle，以及与 PyTorch 的转换关系
4. 完成 P10-P12，P22，P28 的课程作业

第四周：卷积神经网络

任务

1. 完成李沐机器学习：<https://courses.d2l.ai/zh-v2/>卷积神经网络中的
 - 深度卷积神经网络（AlexNet）、使用块的网络（VGG）
 - 网络中的网络（NiN）、含并行连结的网络（GoogLeNet）
 - 批量归一化、残差网络（ResNet）
 - 跑跑“图片分类”竞赛代码。

输出

1. 视频课程学习笔记以及作业

第 5 周、第 6 周为图像部分，可以先跳过，看完自然语言，后期再看此部分。

第五周：计算机视觉

任务

1. 完成李沐机器学习：<https://courses.d2l.ai/zh-v2/>计算机视觉中的
 - 硬件：CPU 和 GPU
 - 更多的专有硬件、多 GPU 训练
 - 多 GPU 训练的实现、分布式训练
 - 图像增广、微调
 - 跑跑“图像分类(CIFAR-10)”或者“狗的品种识别(ImageNet Dogs)”竞赛代码
 - 物体检测、边缘框实现、物体检测数据集、锚框（了解）

输出

1. 视频课程学习笔记以及作业
2. 完成 PyTorch 教程上的代码教程
3. 完成环境配置

第六周：计算机视觉（了解）

任务

1. 完成李沐机器学习：<https://courses.d2l.ai/zh-v2/>计算机视觉中的
 - 区域卷积神经网络（R-CNNs）、单发多框检测（SSD）、你只看一次（YOLO）
 - 多尺度物体检测实现、SSD 实现
 - 语义分割、语义分割数据集、转置卷积、转置卷积是一种卷积
 - 全连接卷积神经网络（FCN）、样式迁移
 - 跑跑“目标检测”竞赛代码
2. PyTorch 包学习
 - [什么是 PyTorch? \(apachecn.org\)](https://pytorch.org/)

输出

1. 视频课程学习笔记以及作业

第七周：循环神经网络

任务

1. 完成李沐机器学习：<https://courses.d2l.ai/zh-v2/>循环神经网络中的
 - 序列模型、文本预处理
 - 语言模型和数据集、循环神经网络
 - 循环神经网络的从零开始实现、循环神经网络的简洁实现
2. 完成李沐机器学习：<https://courses.d2l.ai/zh-v2/>循环神经网络中的
 - 门控循环单元（GRU）、长短期记忆网络（LSTM）、深层循环神经网络、双向循环神经网络
 - 机器翻译与数据集、编码器-解码器结构、序列到序列学习（seq2seq）、束搜索
3. PyTorch 入门中剩下部分的学习
 - [【布客】PyTorch 中文翻译 \(apacheecn.org\)](#)

输出

1. 视频课程学习笔记以及作业

第八周：注意力机制

任务

1. 完成李沐机器学习：<https://courses.d2l.ai/zh-v2/>注意力机制中的
 - 注意力机制、注意力分数、使用注意力机制的 seq2seq
 - 自注意力和位置编码、Transformer
2. 完成李沐机器学习：<https://courses.d2l.ai/zh-v2/>注意力机制中的
 - BERT、BERT 预训练数据集、预训练 BERT、微调 BERT
 - 自然语言推理和数据集、自然语言推理：微调 BERT、优化算法
 - 课程总结和进阶学习

输出

1. 视频课程学习笔记

第九周：自然语言处理

任务

2. NLP 相关基础知识
 - 自然语言处理导引及词向量 [Lecture 1 - Introduction and Word Vector](#)
 - Word2vec 参考资料:
 - [Efficient Estimation of Word Representations in Vector Space](#)
 - [Distributed Representations of Words and Phrases and their Compositionality](#)
 - [word2vec Parameter Learning Explained](#)
 - 依赖分析 [Lecture 4 - Dependency Parsing](#)
 - 语言模型 [Lecture 5 - Language Models and RNNs](#)
 - Transformer 模型、预训练模型 [Lecture 10 - Transformers and Pretrained Model](#)
 - 大模型相关: [大模型基础清华大模型课程](#)、[大模型知识点](#)
 - 多模态学习: [经典论文阅读](#)
3. 实战演练-阶段一
 - [nlp](#)
 - [midlevel_data](#)
 - [nlp_dive](#)

输出

2. 视频课程学习笔记以及作业
3. 阶段一涵盖 NLP 中模型构建的基本步骤，记录实验结果

第十周：自然语言处理

任务

1. NLP 相关任务
 - 翻译任务 [Lecture 7 - Translation, Seq2Seq, Attention](#)

这部分内容中包含的序列模型，注意力机制在第四周的神经网络训练任务部分已经讲述过，所以该部分可以略看。

- 问答任务 [Lecture 11 - Question Answering](#)
- 自然语言生成任务 [Lecture 12 - Natural Language Generation](#)
- 共指消解任务 [Lecture 13 - Coreference Resolution](#)

1. 实战演练-阶段二

- [词嵌入 TransE 实现](#)
- [词嵌入 Glove 实现](#)
- [序列模型与 Attention](#)
- [情感分析模型](#)
- [关系抽取模型](#)
- [大模型](#)

输出

1. 视频课程学习笔记以及作业
2. 阶段二主要涵盖词嵌入学习及基础模型应用两部分内容完成模型调优，记录实验结果

第十一周：自然语言处理

任务

3. 知识+大语言模型相关
 - [T5 and Large Language Model](#)
 - [【生成式 AI】ChatGPT 原理剖析](#) P1-P3、P7-P14
4. 大模型微调相关-基于 LangChain 的大语言模型应用开发，微调以及 RAG
 - [指令微调 Instruction Tuning](#)
 - [常见微调方法：全量微调/P-Tuning/Prompt Tuning/LoRA](#)
 - [吴恩达大模型系列教程：2024 吴恩达 LLM 大模型教程，手把手带你实现大模型预训练和模型微调，中英字幕（附学习课件）](#)

- **【配套代码：GitHub - ConnectAI-E/LangChain-Tutor: 吴恩达大模型系列教程，手把手带你实现大模型预训练和模型微调，中英字幕（附学习课件）】**

LangChain 入门指南，配套吴恩达老师 [ai](#) 课程 复现语言：

Python、NodeJs、Golang】

5. 实战演练-阶段三若对预训练模型微调部分感兴趣，可以参考 huggingface 主页。
 - [文本分类](#)
 - [问答 1](#)
 - [问答 2](#)

输出

2. 视频课程学习笔记
3. 阶段三涵盖预训练模型微调的基本过程，主要用意为熟悉 huggingface 平台，记录实验结果
4. 熟悉大模型的离线知识检索增强生成以及在线知识微调流程，记录实验结果

第十二周：自然语言处理

任务

1. 实战演练：复现一个简单的 Transformer
 1. <https://user.phil.hhu.de/~cwurm/wp-content/uploads/2020/01/7181-attention-is-all-you-need.pdf>
 2. 可在网上寻找一些代码参考与教程

输出

1. 视频课程学习笔记以及作业
2. 阶段四涵盖预训练模型微调的基本过程